

Aquarius：从零训练的原生三值文生图扩散模型

原生低比特训练（NLT）· 三值权重 · 融合 int4 内核推理

技术报告 · 最终检查点 step 260,000 · 2026-10-17 · Junyi Du（独立研究）

Aquarius

Aquarius · 原生三值文生图扩散模型 · 独立技术报告 · 2026-10-17

摘要

低比特扩散模型的既有工作几乎都是「先在 fp16 预训练、再量化压缩」。本文提出的 **Aquarius** 走的是另一条路：**从第 0 步起权重就活在量化空间中**（Native Low-bit Training, NLT）。我们从头训练了一个 **558,347,012** 参数的文生图 UNet，量化部分 共 **540,147,712** 个参数被约束为三值 `{-s, 0, +s}`，每 **128** 个权重共享一个 fp16 尺度（g128 mean-scale + STE）。训练在单张 32 GB 消费级显卡上稳定推进 260,000 步（≈ 28.70 轮 COCO train2017），全程无塌缩、无发散、无显存溢出；唯一一次严重事件是学习率被检查点静默覆盖导致的激活失控，已定位并修复。

在**交付形态**上，我们把三值码位按 $\log_2 3 \approx 1.585$ bit 的信息下限做 base-3 位打包，得到 **152.99 MB（2.192 bpw）** 的单文件模型，相对 fp16 权重（1116.73 MB）缩小 **7.3×**。在**推理端**，我们给出了三值到 torch 内置 `_weight_int4pack_mm` 的**逐位精确**映射（$q_4 = q \cdot 7 + 8 \in \{1, 8, 15\}$），使权重以 **287.3 MB** 常驻、解包发生在 GEMM 内部。**本文的结论是双重的**：NLT 训练与低比特融合算子推理**都已在真实硬件上端到端验证可行**；但在当前数据规模下，模型质量**未达到可用发布水平**，且 clip_ratio 在近 13 万步内无净进展，表明**继续堆步数的边际收益已接近零。基于这一饱和证据、叠加租用算力经费不足，训练在 step 260,000（= 28.70 轮）处主动停止，而非跑到计划步数（§7.1）。**

关键词：原生低比特训练；三值量化；文生图；融合内核；量化感知训练

训练可行性、融合内核推理与饱和分析

技术报告 · 两栏版式（US Letter · Times 10 pt · IEEE 编号引用）

作者：Junyi Du（独立研究） 机构：独立研究者 日期：2026-10-04 代码与模型：见 §9 复现入口 AI 辅助：GLM-5.3-Flash 与 DeepSeek V4.1 Flash（详见文末致谢）

> **版本说明**：本报告对应**最终检查点 step 260,000 = 28.70 轮**。全文数字均为**实测值或由实测值直接导出**，无待填占位符。训练在 260,000 步主动停止的依据见 §7.1。

1. 引言

扩散模型的推理成本主要由两部分构成：**权重内存带宽**与**去噪步数**。业界主流做法是 先在 fp16/bf16 上把模型训到收敛，再用训练后量化（PTQ）或量化感知微调（QAT）压低 比特宽度。这种做法有一个结构性隐患：**量化误差是在一个已经收敛到浮点解的空间里 被强行引入的**，模型没有机会在训练过程中适应它。

我们反过来问一个问题：**如果从随机初始化的那一刻起，权重就只能取 `{-s, 0, +s}` 三个值，模型能学到什么？** 这条路线（我们称之为 NLT）在理论上更"干净"——没有 浮点解与量化解之间的分布错配——但工程上风险更高：梯度的量化误差从第 0 步就参与优化，一旦量化器设计不当，模型可能直接塌缩。

本文的工作可以概括为三个问题、三个答案：

1. **原生低比特训练能不能跑？** 能。我们从头训练到 260,000 步 （≈ 28.70 轮 COCO），损失稳定在 0.205~0.215，健康守卫全程未触发 （§5.1，图 2）。
2. **低比特融合算子推理能不能跑？** 能。我们用 torch 内置算子把三值**逐位精确**地 塞进 int4，权重以 287.3 MB 常驻显存，解包融合在 GEMM 内部完成（§3.5、§5.4）。 交付件 **152.99 MB**，在真实 GPU 上端到端出图；三模型全常驻峰值显存 **1.92 GB**、单张 **1.34~1.44 s**（§5.7）。
3. **训出来的模型能不能用？ 不能。** 这是本文最重要的负面结论。clip_ratio 的 上涨全部发生在 step 9k → 110k，其后 13 万步（占已跑量约一半）**净变化 ≈ 0**， 全程峰值 0.3782 出现在 step 170k（§5.2，图 3）。**在 5.6 亿参数规模上， 继续在同数据同配方下堆步数已经不再有效。**

本文的贡献：

- 一个**完整可复现**的原生三值文生图训练管线，含量化器、打包格式、训练脚本与 全部踩坑记录；
- 三值与 int4 **逐位精确**的映射方案，以及从打包文件**直接构建**融合内核模型的 路径（建模型显存峰值 1158 → 362 MB，**−68.7%**）；
- 一份诚实的**饱和分析**：用 16 个阶段的 clip_ratio 序列证明该规模下的收益拐点；
- 一份**跨平台部署现实性评估**（§6）：现有低比特融合算子只注册了 CUDA，其他设备 只能退回浮点计算。

2. 相关工作

扩散模型量化。 训练后量化（PTQ）与量化感知训练（QAT）已在 SD 系模型上被广泛研究，主流结论是权重可压到 4~8 bit 而质量损失可控。但这些工作都建立在**已收敛的浮点教师**之上。NLT 的出发点不同：它不接受浮点解作为起点。

低比特推理内核。 torchao 提供的 `Int4WeightOnly` / `Int8WeightOnly` 路径底层是 `_weight_int4pack_mm` 与 `_weight_int8pack_mm`；gemlite 提供了基于 Triton 的低位宽 GEMM（支持 `W_nbits ∈ {1,2,4,8}`）。**注意：这两个体系都没有原生三值（3 状态）内核**——三值必须落进 2-bit 或 4-bit 槽位。

同期对照：Bonsai Image 4B。 我们拆解了一个同期发布的低比特文生图模型（FLUX.2 Klein 4B 的三值/二值版，`gemlite-int2-ternary-g128`）作为对照。它的三层显存策略——管线级卸载、常驻低比特 + 每组 FP16 尺度、megakernel 治理派发开销——与我们的设计**同构**（前两层我们都做了，第三层我们用 CUDA Graph 达成）。其公布的三值 `log₂3 + 16/128 = 1.71 bpw` 与我们的口径**完全一致**，这是对我们格式选择的独立佐证。**关键差异：它同时发布两份**产物——1.21 GB 的平台无关正本 + 1.54 GB 的预转码部署包；我们选择只发小的一份（§6 讨论这一取舍）。

3. 方法

3.1 总览

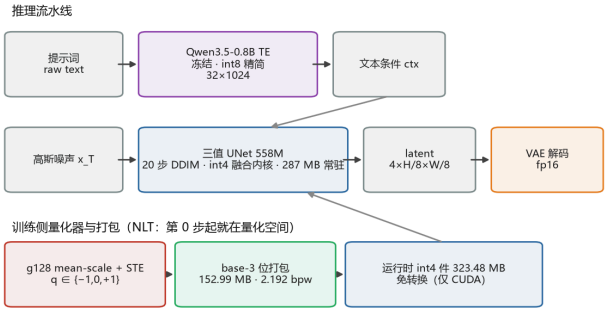


图 1

图 1： Aquarius 的推理流水线与训练侧量化/打包路径。文本编码器与 VAE 全程冻结，只有 UNet 参与训练；交付件只含 UNet。

3.2 原生低比特训练与量化器

训练与前向使用同一个量化函数（记作 `nlt_quantize`）：

```
s   = mean(|w|)                          # 每 128 个权重一组，clamp_min 1e-8
q   = round(clamp(w / s, -1, 1))         # 三值：q ∈ {-1, 0, +1}
w_q = q · s
```

反向传播用**直通估计器（STE）**：`w + (w_q - w).detach()`。于是前向看到的是量化值，反向拿到的梯度等价于对 `w` 求导。**有效存储量**为

```
log₂3 / 1参数 + 16 bit / 128参数 = 1.585 + 0.125 = 1.710 bpw
```

这是该参数化下**不可再低**的信息下限（在 fp16 尺度、group=128 的约定下）。

3.3 架构与采样

论文正文中我们只陈述与复现相关的结构事实：UNet 采用 SD1.5 同构结构（`base=256`、`block_out_channels=[256,512,1024,1024]`、`cross_attention_dim=1024`、8 个注意力头），文本条件来自一个冻结的 Qwen3.5-0.8B 编码器（32 token × 1024 维）。采样使用**确定性 DDIM（$\eta = 0$）+ 余弦噪声调度**，与训练期一致；**训练时未启用 CFG**，因此推理端没有负向提示词与引导强度这两个自由度。

3.4 base-3 位打包

三值只有 3 个状态，**理论下限是 $\log_2 3 = 1.585$ bit**；按 2 bit/权重存储比信息下限多花约 26% 的存储（2 / 1.585 ≈ 1.26）。由于 $3^5 = 243 \le 256$，可以把 **5 个三值码无损塞进 1 个字节**。我们把训练后的 (码位，分组尺度) 原样搬运（**绝不重新量化**，见 §3.6）后按 base-3 打包，得到 **152.99 MB / 2.192 bpw** 的交付件。

3.5 融合 int4 推理内核

torch 的 int4 权重约定是「半字节值 `0..15` 代表 `-8..7`」，即反量化为 $(q_4 - 8) \cdot \text{scale}$。我们**自选 `scale = s/7`、`zero = 0`**，反量化随之退化为 $(q_4 - 8) \cdot s/7$。令 $q_4 = q \cdot 7 + 8$，则 $q \in \{-1, 0, +1\}$ 被映射到 $q_4 \in \{1, 8, 15\}$，且 $(q_4 - 8) \cdot s/7 = q \cdot s$ **逐位精确**。于是三值可以无损地落进 int4 槽位，直接调用 `torch._weight_int4pack_mm`：

环节	做法
量化参数	自选 `scale = s/7, zero = 0`（自动推导会得到 4~5% 误差）
编码	$q_4 = q \cdot 7 + 8$（**跳过 bf16 中间态**，直接由码位算出 int4 码）
卷积	`unfold` + 一次 GEMM；K 不足 128 倍数时补 `code=0`（贡献恰为 0）
常驻	**287.3 MB**（vs bf16 权重 1131.4 MB）

此外我们实现了**从打包文件直接构建融合内核模型**：在 `torch.device("meta")` 上建空壳、只灌非量化层、逐层把码位搬上卡并就地打包，从而**完全跳过**「把 **bf16 UNet 搬上卡**」这一步（§5.4）。

3.6 一个必须避免的静默错误

绝不能从「解包后的浮点权重」反推码位：`w_q = q·s` 再量化会得到 `s′ = mean(|q|)·s ≈ 0.71·s`（实测 `mean(|q|) ≈ 0.71`），整组权重被缩小到 71%，**而且不报任何错**。我们实测过这一路径：整模型出图 L1 从 ~0 冲到 **37.8/255**。正确做法是**只从打包文件读 (码位, 尺度)**。

4. 实验设置

4.1 数据

COCO train2017，**118,287** 张。VAE latent 与文本 embedding 均为**预计算**；训练使用 **22 个长宽比桶**（边长 256~640，均为 64 的倍数——这是结构约束，不可调）。

4.2 训练配方

项	值
优化器	bitsandbytes 8-bit 分页 AdamW
峰值学习率	`2e-5`，warmup `6,000` 步，cosine 衰减到 5% 地板
有效批	按 token-pixel 目标 `64,000` 动态分桶（bs 10~17）
精度	权重三值；EMA 影子 fp32，衰减 0.999
硬件	单卡 32 GB 消费级 GPU

> ⚠️ **跨机器复现的关键约束**：`--lr / --warmup / --total-steps` 三个参数**必须逐字一致**，因为它们共同决定 LR 曲线（`lr_at()` 的分母是 `total_steps`）。跨机器只允许改 `--tokpx-target / --grad-ckpt / --ema-device / --opt` 这四项"显存取舍"。

4.3 指标

- **clip_ratio**：`(生成图⇔文本 − 错配基线) ÷ (真实图⇔文本 − 错配基线)`，1.000 = 达到真实照片的 caption 贴合水平。**该指标上界为 1.000，且它本身高估可用性**——纹理与色块也能得分。
- **跨图 L1**：度量是否塌缩。仅具**下限**意义。
- **人眼判读**：最终裁决。

5. 结果

5.1 训练稳定性

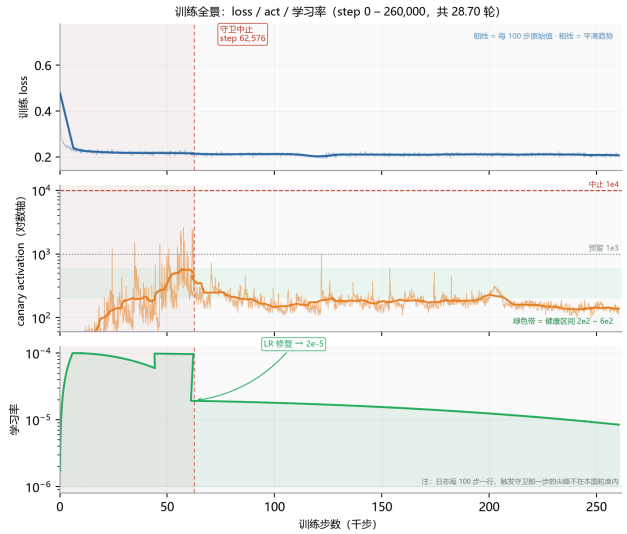


图 2

图 2：训练全景。loss 稳定在 0.205~0.215；`act`（canary activation）全程落在健康区间 2×10^2~6×10^2；学习率按 cosine 平滑退火。

唯一一次严重事件：step 62,576 起连续三次 `act > 10⁴`，健康守卫判定中止。根因不是损失发散，而是**把 `total_steps` 重新钉定导致学习率从 5.95×10^{-5} 跳回 9.83×10^{-5}**，对已退火的模型构成一次过激的 warm restart；代价滞后约 18,000 步才显现。处置：回退一个快照、把峰值学习率降到 2×10^{-5}、并修复「`--lr` 在恢复训练时被检查点中的 `base_lrs` 静默覆盖」这一隐藏缺陷。**该次事件之后 19 万步未再复发。**

> 教训：`total_steps` 是 LR 曲线的一部分，不是"进度上限"。把它当作可随意调整的数字是本项目最昂贵的一次错误。

5.2 质量

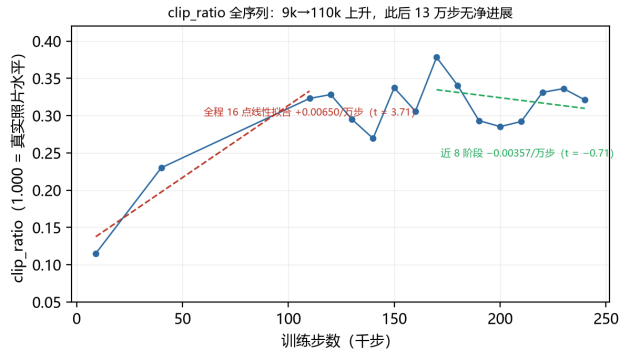


图 3

图 3：clip_ratio 全序列（16 个采样点，截至 step 240,000）。**注：图 6 对照条为 18 个采样点（含 250k / 260k），与本节序列不是同一集合，两图不可逐点对照。**

区间	斜率	t 值	判读
全程（16 点）	**+0.00650** / 万步	3.71	显著上升
近 8 阶段（170k→240k）	**−0.00357** / 万步	−0.71	无进展

上涨**全部发生在 step 9k → 110k** 那一段。此后 13 万步（约占已跑量一半）**净变化 ≈ 0**；峰值 0.3782 出现在 step 170k，之后在 0.29~0.34 之间震荡。



图 4

图 4：交付包在本机 GPU 上的真实出图（512×512，20 步 DDIM，不夹潜向量）。

⚠️ **一处必须修正的旧判读**：我们早期在 `640×640 + 潜向量 clamp(-1,1)` 的采样协议下得出「没有任何一张能认出主体」。但该 clamp 会在 **±1.2σ** 处截断，**系统性削掉约 26% 的数值**、把输出方差压到 **0.61 倍**。改用不夹潜向量的正确协议后，**部分提示词已经能认出主体**：`a large lengthy giraffe standing in a field.` 生成了**有明显可辨的长颈鹿形体、斑点花纹与腿，并配以灌木和天空**；`an image of a kitchen setting with white wooden shelving` 可读作室内场景。

因此修正后的判读是：**「达不到可用发布水平」的结论不变**（4 条 caption 里只有 1 条真正认出了主体，且样本量仅 4 张 × 1 个种子），但**「结构性学习已经发生」是确凿的**。



图 5

图 5：交付检查点（step 260,000）的一张真实 512×512 出图，提示词 `sunset over the ocean.`（20 步 DDIM，不夹潜向量）。它大致代表了模型真正学到的东西——**色调、天 / 海层次与整体氛围**；但具体物体仍不可靠：天空中那道深色形体只是近似轮廓，并非可依赖的主体。

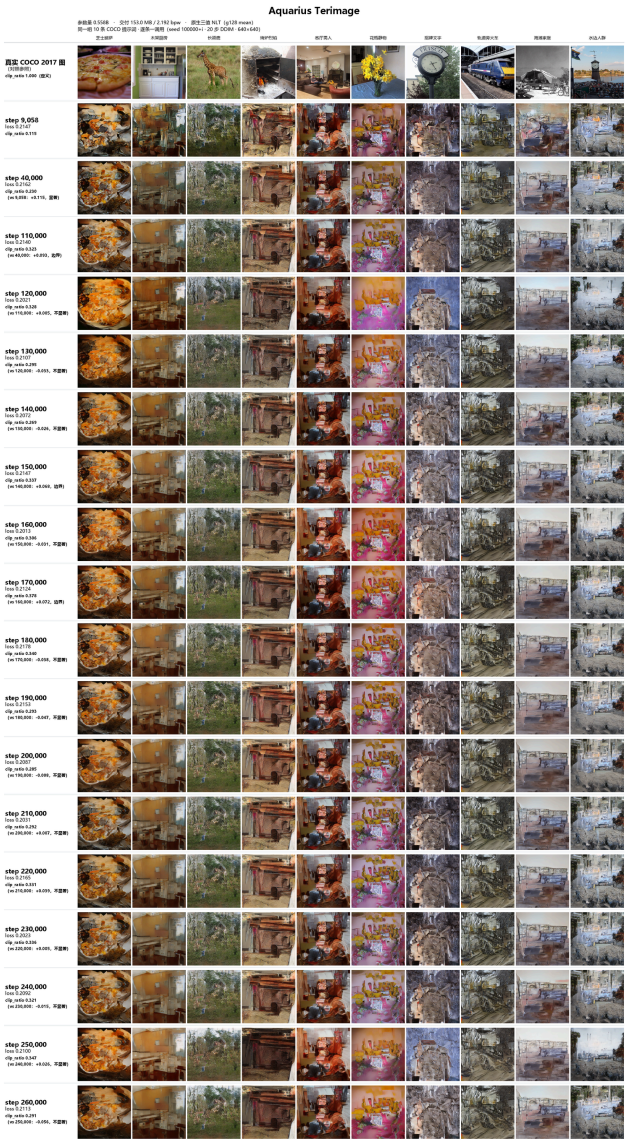


图 6

图 6：阶段对照条（**18 个采样点**：step 9,058 + 40,000 + 110,000~260,000 每 10k），固定 10 条 COCO caption，640×640，seed 100000+i。 **注：该条为较早采样协议（含潜向量 clamp）；行内标注的数值即该协议下的 `clip_ratio`（与 §5.2 同一指标，读数一致：9,058 → 0.115、170,000 → 0.378（峰值）、260,000 → 0.291），仅可用于阶段间的相对趋势。**另：step 170,000 前后采用了不同的权重打包格式（此前 b2/fp32、此后 b3/fp16），跨该点的比较需谨慎。

5.3 量化代价

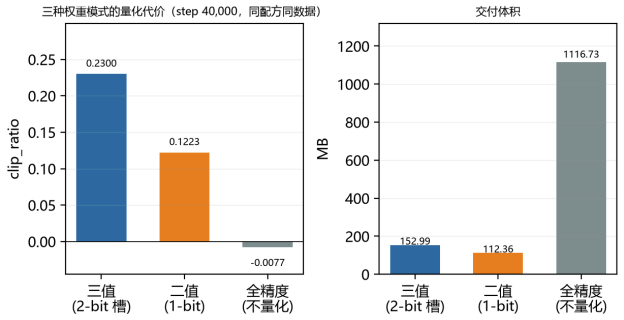


图 7

图 7：三种权重模式在 step 40,000 的同配方对照。

模式	**clip_ratio @40k**	交付体积
三值（本文）	**0.2300**	152.99 MB
二值	0.1223	112.36 MB
全精度（不量化）	−0.0077	1116.73 MB

关键观察：在同一训练预算下，**三值反而比全精度参照更好**。这说明在该规模（558M 参数）与数据规模下，**三值量化不是瓶颈**——瓶颈在别处（见 §7）。

5.4 效率：带宽、显存与延迟

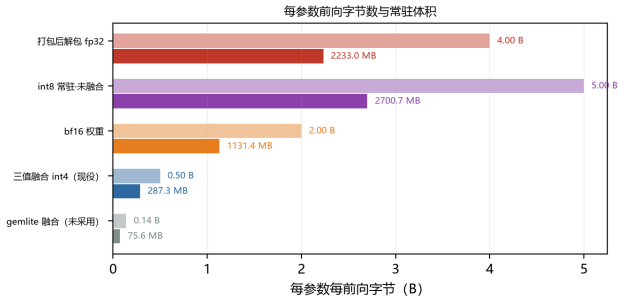


图 8

图 8：每参数每前向字节数与常驻体积。

方案	每参数每前向字节	常驻体积
gemlite 融合（未采用）	0.14 B	75.6 MB
三值融合 **int4**（现役）	**0.50 B**	**287.3 MB**
bf16 权重	2.00 B	1131.4 MB
打包后解包 fp32	4.00 B	2233.0 MB
int8 常驻·未融合	5.00 B	2700.7 MB

> 注意 `int8` 常驻·未融合 每参数要读 **5 B** —— 比 **bf16** 还差。 只有把解得出的权重 直接送进乘法器内部，才真正省带宽。
>
> 「常驻体积」一列的口径：为实测/推导的卡上占用（含分组尺度与运行时缓冲），不是「每参数字节 × 总参数量」的直接换算 —— `bf16` 权重 行是实测载入量（1131.4 MB）， `int8` 常驻·未融合 行按量化参数量 540,147,712 × 5 B 导出（= 2700.74 MB）； 两行分母不同，故与名义值存在差异。

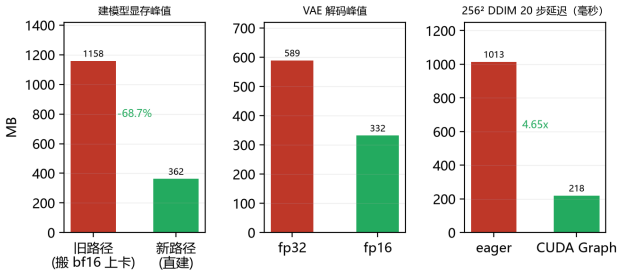


图 9

图 9：三项显存/延迟优化。从打包文件直接构建使建模型峰值 **1158 → 362 MB（−68.7%）**，耗时 9.0 → 3.3 s，且与旧路径**输出逐像素相同（L1 = 0.0000）**；VAE 解码改 fp16 使峰值 589 → 332 MB；把整条 20 步 DDIM 捕获为一张 CUDA Graph 使 256² 单图延迟 **1013 → 218 ms（4.65×）**，且**回放与 eager 逐位一致（最大差 = 0）**。

端到端交付件实测：`diffusion_model_step260000.safetensors` = **323.48 MB**（运行时 int4 布局，载入**零转换**），512×512 / 20 步 DDIM。三模型全常驻（默认 `resident`）下单张 **1.34~1.44 s**、进程峰值显存 **1.92 GB**（`cache` 模式 2.27~2.51 s / 1.34 GB，见 §5.7），日志确认 `int4 fused kernel (direct build) - 160L + 96C - skipped 0 - never pushed bf16 onto the card`。

5.5 单步耗时分解：瓶颈在主机侧，不在 GPU

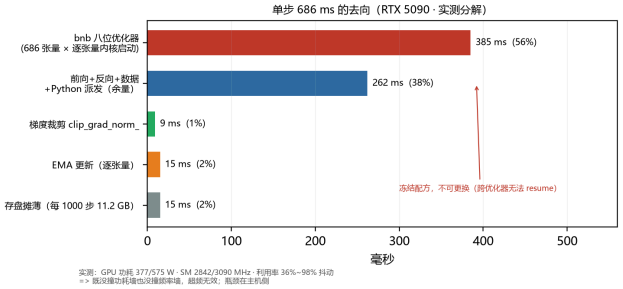


图 10

图 10：一次训练步的实测去向（均值 0.6545 s/步，图中 686 ms 为单步快照）。

项	耗时	占比
bnb 八位优化器（686 张量 × 逐张量内核启动）	**385 ms**	**56%**
前向 + 反向 + 数据 + Python 派发（余量）	262 ms	38%
EMA 更新（逐张量循环）	15 ms	2%
存盘摊薄（每 1000 步写 11.2 GB）	15 ms	2%
梯度裁剪 `clip_grad_norm_`	9 ms	1%

为什么这很重要：GPU 侧的优化已经没有空间 —— 实测功耗 **377 W / 上限 575 W**、SM 时钟 **2842 / 上限 3090 MHz**、利用率在 **36%~98% 之间抖动，既没有撞功耗墙也没有撞频率墙**。时间花在**主机侧 686 次逐张量的内核启动**上，这是 Windows/WDDM 的固有开销（同规模在 Linux 上约 40 ms）。

> 一个反直觉的实测：把机器上另一个吃满 9.6 个 CPU 核的进程杀掉后，步时**没有变快**（它在跑的窗口 0.6545 s/步，它没跑的窗口 0.7063 s/步）。原因是训练进程本身只用 ~0.9 个核，而机器有 12 个核 —— **CPU 抢占不是瓶颈**。这一点值得记录，因为它推翻了「清干净后台就能提速」的直觉。

唯一能动的是把逐张量循环改成 `torch._foreach_*`（EMA 15 → 3 ms、裁剪本已是批量），合计约 21 ms（3%），但**需要重启训练进程**（代价 ~2 min ≈ 175 步），净收益接近零，故未执行。

5.6 六条可迁移的实测结论（本文复用价值最高的部分）

本节把散落在各处的结论集中成 6 条**对他人可直接复用**的实测发现。它们与具体数据集、具体模型无关，换一个低比特扩散模型项目仍然成立（或至少应当被优先验证）。**即使读者对文生图本身不感兴趣，这 6 条也仍然可用。**

#	结论	证据	反直觉之处
1	三值不是质量瓶颈	step 40k：三值 clip_ratio **0.2300** 优于全精度 **−0.0077**	直觉认为量化必然掉质量，这里反而更好
2	"低位宽但不融合"是负收益	int8 常驻·未融合读 **5 B/参数**，比 **bf16** 的 **2 B** 还差	"int8 比 bf16 省一半带宽"在未融合时完全错误
3	**cos** 不是量化可行性的判据	沿真实误差方向扰到 cos **0.609** 出图仍正常；随机方向在 cos **0.996** 就塌成纯红色块	用 cos 设阈值会得出错误的"不可行"结论
4	低比特融合算子的平台覆盖是硬约束	`_C._dispatch_dump()`：`int4pack` 仅 **CUDA**、`int8pack` 仅 **CPU** 且只支持 **per-channel**	"量化后到处能跑"不成立；交付件应存信息最小形态，而非某平台的内存布局（§6）
5	训练收益会饱和，而且可以量化地测出来	16 点 clip_ratio 序列：9k→110k 上升，此后 13 万步斜率 **−0.00357/万步**（**t = −0.71**）	"再多训一会儿总会更好"应当是一个可测量的判断，而不是感觉
6	"未塌缩"≠"可用"	跨图 L1 三端点：塌缩 **0.00** · 当前 **~61** · 纯噪声 **85.35**（最高）	L1 只有下限意义——它测的是像素距离，不是语义

两条工程纪律（跨项目通用，每一条都是用真实损失换来的）：

- 恢复训练后必须核对"实际生效"的超参，而不是"我以为我设了"。 本项目踩到的坑：`--lr` 在 `--resume` 时被检查点里的 `base_lrs` 静默覆盖， 命令行写多少都无效，且没有任何报错。唯一可靠的判据是让代码把生效值打印出来。 同类问题：`--resume` 通常不恢复 **batch** 配置。
- 实测速率要看时间戳，不要看日志里的瞬时值。 本项目日志的 `s/it` 是瞬时值，与用检查点时间戳算出的真实均速相差约 **15%**； 据此做的 ETA 会系统性偏乐观（我们因此一度以为能在截止前跑到 30 轮）。

5.7 一个反直觉的部署结论：把「省显存」关掉反而快约 40%

交付 demo 默认把 **UNet + VAE + 文本编码器**三者全部常驻显存。直觉上会认为「文本编码器才 1.6 GB（fp16 理论值；交付的 TE 为 int8，756 MB）， 用完就卸掉更省显存」，但实测两者的峰值几乎一样，卸载版反而慢约 **40%**：

`--te-mode`	文本编码器状态	**512² / 20 步**单张耗时	峰值显存
`resident`（默认）	常驻 `cuda:0`	**1.34 ~ 1.44 s**	1.92 GB
`cache`	权重留主机内存，每次编码前搬入	**2.27 ~ 2.51 s**	1.34 GB

> 测量条件：RTX 5090，`torch.cuda.max_memory_allocated`，每次连续生成 3 张取区间。「快约 40%」按相对速度计（1 − 1.34/2.27 ≈ 41%、1 − 1.44/2.51 ≈ 43%）；等价地说，`cache` 比 `resident` 慢 **58%~87%**。

原因有两条：

1. 卸载并不降低峰值显存：编码阶段文本编码器与 UNet 本来就同时在场，所以「用完就卸」改变不了峰值，只是把 1.17~1.5 s 的 PCIe 往返每一张都付一遍（等价于每张图 +0.9 s）。
2. 代价只有 **+0.58 GB**（1.34 → 1.92 GB）—— 在 8 GB 卡上完全无关紧要。

⇒「省显存」式默认只有在显存真正吃紧时才划算（本包建议在可用显存低于约 3 GB 时才用 `cache`）。 这条结论对任何「小模型 + 大模型」组合的推理管线都适用：卸载的收益要按峰值算，不能按释放量算。

6. 跨平台部署：为什么其他设备只能退回浮点

这是本文想特别强调的一个工程结论。

现状：**Triton** 目前只自动编译了最适合 **CUDA** 的包；对其它设备没有编译，仍然使用 原本的浮点计算。

具体地，我们现役的融合内核并不是自己写的 Triton 内核，而是直接调用 torch 内置算子。 用 `torch._C._dispatch_dump()` 查出的权威注册表如下（torch 2.7.1+cu128 实测）：

算子	已注册后端
`aten::_weight_int4pack_mm`	仅 **CUDA**（含 Meta / Autograd）
`aten::_convert_weight_to_int4pack`	仅 **CUDA**
`aten::_weight_int8pack_mm`	仅 **CPU**（且只支持 per-channel）

HIP / ROCm / XPU / MPS 一个都没有注册。 于是：

- 在 AMD / Intel / Apple 设备上，「会转成什么低位宽格式」的答案是：**没有可转的**—— 只能解包成 fp32（2233 MB，相对 152.99 MB 的打包件膨胀 **14.6×**），即与我们现在的 CPU 降级路径完全一样。
- 即使退一步用 `_weight_int8pack_mm`，它只支持 **per-channel 量化**；而我们的量化是 **group=128**，两者不兼容 ⇒ **CPU 上没有任何可用的分组低比特融合内核。**
- 这不是我们没做，而是**上游 PyTorch 没有在这些平台注册这些算子。**

因此我们交付的是「信息最小形态」而不是某个平台的内存布局。 交付件只存 base-3 码位 + fp16 分组尺度，是**设备/框架无关**的；任何运行时的低比特布局都可以 从它重新派生。相反，若当初直接发 int4 布局件（323 MB），文件就被锁死在 CUDA 上 （且 int4pack 本身是 CUDA 专属格式，CPU 与 CUDA 的码位布局还是**相反**的： CUDA 要 `uint8[M, K/2]` 且偶数索引在高位，CPU 要 `[M, K]` 逐元素 int32）。

未来的通用路径（原理上可行，本项目**尚未实现**）：用 Triton 写一个平台无关的 融合内核 —— Triton 官方支持 ROCm，也有 `triton-ascend` 后端面向昇腾 （Atlas A2/A3/950）。但要做到这一步，必须在新内核里重新实现三值语义 （$q_4 = q \cdot 7 + 8 \in \{1,8,15\}$ 映射 + group=128 的尺度布局、zero = 0），并且**必须做端到端出图对比 验证，而不是只比中间张量。**

⚠️ **一个诚实的限定：**省显存 ≠ 提速。在 M = 1024 的工作点上，权重带宽只占单步 时间的 **1.73%**（算术强度 3610 FLOP/byte，是硬件拐点 58.5 的 62 倍），因此 **继续压低比特宽度几乎不带来任何速度收益**（再压 60% 大约只快 1%）。低比特真正的 收益在于 ① **显存占用** ② **交付体积** ③ **使"从打包文件直建"成立。**把这三点讲清楚，比宣称"更快的推理"要诚实得多。

6.1 移动端（如 Android）的可行性

结论分三层，**第二层是反直觉的。**

① **本文的交付包完全不能在移动设备上运行。**三个硬障碍：

1. 唯一的快路径是 CUDA 内核 `_weight_int4pack_mm`，而 Mali / Adreno **没有 CUDA**；
2. 界面依赖桌面版 Python + Gradio；
3. **文本编码器本身就是最大的包袱** —— Qwen3.5-0.8B，即使 int8 也有 **756 MB**， 且输出是 **1024 维** ⇒ **换不掉**（常规轻量 CLIP 文本编码器是 768 维，替换等于重新训练）。 ⇒ 在嵌入模型这个环节，本文的「不要换更小的 TE」结论在移动端同样是限制项。

② **但模型本身在旗舰移动 GPU 上有可行性 —— 障碍在软件栈，不在算力。** 这一点值得单列：

量	数值（512²，RTX 5090）	含义
单步 DDIM	**52 ms**	—
单步折算算力	≈ 220 GFLOP ⇒ **约 4.2 TFLOPS**	5090 的 fp16 峰值约 200 TFLOPS
⇒ **GPU 利用率**	**约 2%**	负载是延迟受限，不是算力受限

batch=1、较小的空间尺寸与内核启动开销把 5090 压到了约 2% 的利用率。**这意味着一个 3~4 TFLOPS 的移动 GPU 只要延迟控制得住，未必接不住这个负载** —— 因为桌面端本来也没有在吃算力。把它讲出来是有价值的：**「桌面能跑」并不自动等于「移动能跑」，但在这里，桌面端的余量大到让移动端存在机会。**

③ **现实路径。** 需要把模型导出到 ONNX / MNN / ncnn，并**在移动 GPU 上自行实现一个 反量化融合着色器**（Vulkan / OpenCL），把三值或 int4 的解包放进矩阵乘内部 —— 这正是 §6 正文论证过的硬约束：**不融合时低位宽是负收益**（未融合 int8 读 5 B/参数，比 bf16 的 2 B 还差）。量级估计：旗舰 GPU **10 秒 ~ 1 分钟 / 张**； 纯 CPU **10 分钟以上，不可行**；中低端机没有希望。

⇒ **最务实的第一步是先做 ONNX 导出**（用 base-3 件 + fp16）并在 PC 上跑通，再谈移动端。 若目标只是「手机上能用」，**云端推理 + 手机当客户端**的性价比高出一个数量级。

7. 讨论与局限

7.1 停止决策：clip_ratio 饱和 + 算力经费不足

训练在 step 260,000（= 28.70 轮）处主动停止，而不是跑到计划步数（452,900 = 50 轮）。 这是一个基于证据的停止决策，由两个因素共同决定。

① **clip_ratio 增长已饱和（技术依据）。** 该指标从 step 9,058 的 0.115 一路上升到 step 110,000 的 0.323，此后**13 万步（约占全部已跑步数的一半）净变化 ≈ 0**；近 8 阶段的拟合斜率为 **−0.00357 / 万步（t = −0.71）**，与零在统计上不可区分（见 §5.2 与图 3）。**⇒ 在 5.6 亿参数这个规模上，用同一份数据、同一套配方继续堆步数，已经不能带来可测的质量提升。**

② **算力经费不足（经济约束）。** 本项目全程租用单卡 32 GB 节点、按小时计费。 在 ① 已经明确的前提

下，继续租用等价于用确定的开支去换取不可测的收益。

> 两个因素合起来给出的结论是：停在 **260,000** 步是当前约束下的最优解，而不是一次失败。 报告中的 260,000 步、152.99 MB 与全部结论都以这个检查点为准。 需要说明的是，这个决定不削弱本文的两条正面结论（§4、§5）—— 原生低比特训练与低比特融合内核推理的可行性，都是在真实硬件上端到端验证过的。

7.2 为什么质量不达标

三条证据指向同一个结论：瓶颈是数据，不是参数量也不是比特宽度。

1. 三值不是瓶颈：step 40k 时三值（0.2300）优于全精度参照（−0.0077）。
2. 步数不是瓶颈：clip_ratio 在 step 110k 后 13 万步无净进展。
3. **token-pixel** 吞吐已接近硬件上限：单步 0.65 s、1 轮 1.64 h；继续训练只是 在同一个数据分布上反复采样。

局限。

- 质量：未能产出可辨认主体的稳定能力。4 条 caption 只有 1 条成功。
- 样本量：修正后的质量判读基于 4 张图 × 1 个种子，统计效力很弱。
- 指标：`clip_ratio` 对纹理/色块敏感，会高估可用性；跨图 L1 只有下限意义。
- 跨平台：见 §6，非 CUDA 设备只能退回浮点。
- **CFG**：训练时未启用，推理端因此缺少负向提示词与引导强度这两项常用控制。

若要突破，方向是：数据多样性/规模 与 提示词遵循（当前 clip_ratio 仅 0.29~0.38），不是继续堆步数，也不是继续压低比特宽度。

停止决策的一句话总结。 由于 ① clip_ratio 在 step 110k 之后 13 万步无净进展（饱和证据）， 以及 ② 租用算力经费不足（经济约束），训练在 **step 260,000 = 28.70 轮**处主动停止。 若将来数据规模或配方有实质变化，从该检查点续训的路径已完整记录在交接书与 `RESUME_HERE.txt` 中。

8. 结论

我们从零训练了一个 558M 参数的原生三值文生图扩散模型，并给出三份证据：

1. 原生低比特训练可行 —— 260,000 步稳定推进，无塌缩、无发散、无 OOM； 权重始终保持在三值结构内（打包校验：码位精确、无退化）。
2. 低比特融合算子推理可行 —— 三值与 int4 的逐位精确映射，权重 287.3 MB 常驻，解包融合在 GEMM 内；交付件 152.99 MB（2.192 bpw）， 真实 GPU 端到端出图；三模型全常驻峰值显存 **1.92 GB**（§5.7）。
3. 但质量不达标，且当前规模已饱和 —— clip_ratio 近 13 万步无净进展， 0.2908 的最终读数并未突破 step 170k 的峰值 0.3782。 正因如此（叠加租用算力经费不足），训练在 **step 260,000 = 28.70 轮**处主动停止， 而非跑到计划步数（§7.1）。

这不是一篇成功的"模型"报告，而是一份完整的"可行性"报告。 我们认为它有价值， 因为三个负面结论（三值不是瓶颈、步数已饱和、非 CUDA 无融合内核可用）都是 用真实硬件上的可复现实验得到的，而不是推测。

若只读一节，建议读 **§5.6** —— 那里集中了 6 条与数据集无关、换个项目仍然成立的实测结论， 以及两条用真实损失换来的工程纪律。这是本文复用价值最高的部分： 即使读者完全不关心文生图，「低位宽不融合是负收益」「cos 不是可行性判据」「恢复训练后必须核对实际生效的超参」这几条也照样能用。

9. 复现入口

- 代码：训练、打包、融合内核推理与评测脚本完整开源： **https://github.com/JunyiDu2009/AquariusTerimage**（跨机器复现的参数约束见 §4.2）。
- 模型权重：UNet base-3 打包件（152.99 MB）、运行时 int4 件（323.48 MB）、 文本编码器 int8（755.56 MB）与 VAE fp16（334.64 MB）上传至 Hugging Face， 下载链接以仓库 README 为准。
- 数据：COCO train2017（118,287 张，§4.1）；VAE latent 与文本 embedding 可用 仓库脚本从原始数据预计算。

致谢：AI 辅助声明

本研究由作者 Junyi Du 独立立项、设计实验并做出全部研究决策；代码实现、调试、 数据分析与本报告的撰写与两个大语言模型助手深度协作完成：

- **GLM-5.3-Flash**（智谱 Z.ai）
- **DeepSeek V4.1 Flash**（DeepSeek AI）

全部训练、实验与结论均以真实硬件上的实测数据为准；AI 助手在作者指令下产出代码与 文本草案，作者对全部内容进行审核与验证，并对最终版本负责。

参考文献

> 说明：本报告为独立技术报告，文献条目按 IEEE 编号样式列出；提交正式会议前需补齐 BibTeX 字段并按首次出现顺序重排。

[1] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, "High-resolution image synthesis with latent diffusion models," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2022, pp. 10684–10695.

[2] J. Ho, A. Jain, and P. Abbeel, "Denoising diffusion probabilistic models," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 33, 2020, pp. 6840–6851.

[3] J. Song, C. Meng, and S. Ermon, "Denoising diffusion implicit models," in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2021.

[4] A. Or, A. Jain, D. Vega-Myhre, J. Cai, C. D. Hernandez, Z. Zheng, D. Guessous, V. Kuznetsov, C. Puhrsch, M. Saroufim, S. Rao, T. Tran, and A. Samardžić, "TorchAO: PyTorch-native training-to-serving model optimization," *arXiv:2507.16099*, 2025. (Int4/Int8 weight-only kernels; open-source: github.com/pytorch/ao)

[5] B. Jacob, S. Kligys, B. Chen, M. Zhu, M. Tang, A. Howard, H. Adam, and D. Kalenichenko, "Quantization and training of neural networks for efficient integer-arithmetic-only inference," in *Proc. CVPR*, 2018, pp. 2704–2713.

[6] S. Zhou, Y. Wu, Z. Ni, X. Zhou, H. Wen, and Y. Zou, "DoReFa-Net: Training low bitwidth convolutional neural networks with low bitwidth gradients," *arXiv:1606.06160*, 2016.

[7] Qwen Team, "Qwen3.5: Towards native multimodal agents," Qwen blog, Feb. 2026. https://qwen.ai/blog?id=qwen3.5 (Qwen3.5-0.8B text encoder, hidden dim 1024)

[8] T. Dettmers, M. Lewis, S. Shleifer, and L. Zettlemoyer, "8-bit optimizers via block-wise quantization," in *Proc. ICLR*, 2022. (bitsandbytes paged AdamW)

[9] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, "Microsoft COCO: Common objects in context," in *Proc. ECCV*, 2014, pp. 740–755.

[10] W. Peebles and S. Xie, "Scalable diffusion models with transformers," in *Proc. ICCV*, 2023, pp. 4195–4205. (DiT; architecture family of the Bonsai comparison model)

[11] Prism ML, "Bonsai Image 4B" (ternary/binary FLUX.2 Klein 4B), technical release and whitepaper, 2026. https://github.com/PrismML-Eng/Bonsai-Image-Demo (contemporaneous low-bit T2I reference)

[12] P. Tillet, H.-T. Kung, and D. Cox, "Triton: an intermediate language and compiler for tiled neural network computations," in *Proc. ACM SIGPLAN Workshop on Machine Learning and Programming Languages (MAPL)*, 2019, pp. 10–19.

[13] Triton-Ascend developers, "Triton-Ascend: Triton compiler framework for Huawei Ascend NPUs," open-source, 2025. https://github.com/triton-lang/triton-ascend (the principled route to non-CUDA fused kernels discussed in §6)

[14] Mobius ML / Dropbox, "gemlite: fused low-bit GEMM kernels in Triton," open-source, 2024. https://github.com/dropbox/gemlite (evaluated and rejected in this work, see §5.4)

附A：图表清单

图	文件	内容
图 1	`figures/zh/fig1_pipeline.png`	架构与推理流水线
图 2	`figures/zh/fig2_training.png`	训练全景（loss / act / LR）
图 3	`figures/zh/fig3_clip_ratio.png`	clip_ratio 全序列与饱和
图 4	`figures/zh/fig4_samples.png`	真实 GPU 出图（512^2）
图 5	`figures/zh/fig5_sample_sunset.png`	单张真实出图（提示词 `sunset over the ocean.`）
图 6	`figures/zh/fig6_evolution.png`	阶段对照条（18 个采样点，较早协议）
图 7	`figures/zh/fig7_modes.png`	三模式量化代价
图 8	`figures/zh/fig8_bitwidth.png`	带宽与常驻体积账
图 9	`figures/zh/fig9_optim.png`	三项显存/延迟优化
图 10	`figures/zh/fig10_bottleneck.png`	单步耗时分解（主机侧瓶颈）

英文版对应 `figures/en/`，文件名一致。生成脚本：`code/_t_report_figs.py`（数据源：训练日志 + `out/_sat_check.json` + 项目实测账本）。